

Stokastiska variabler i två dimensioner

Definition

- En *stokastisk variabel*, (X, Y) , är en reellvärd funktion definierad på ett utfallsrum (Ω) . $(X, Y): \Omega \rightarrow \mathcal{R}$

Definition

- Funktionen

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$$

kallas *fördelningsfunktionen* för (X, Y) .

- Om (X, Y) båda antar ett uppräkneligt antal värden sägs (X, Y) vara *diskret*.

Definition

Med den *simultana sannolikhetsfunktionen* för en diskret tvådimensionell stokastisk variabel (X, Y) menas

$$p_{X,Y}(j, k) = P(X = j, Y = k) \quad , j \in \Omega_X, k \in \Omega_Y$$

Den *marginella sannolikhetsfunktionen* för X fås ur

$$p_X(j) = \sum_{k=0}^{\infty} p_{X,Y}(j, k)$$

Dessutom gäller

$$\sum_{j=0}^{\infty} \sum_{k=0}^{\infty} p_{X,Y}(x, y) = 1$$

Definition

Om det finns en funktion, $f_{X,Y}(x, y)$, så att

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(s, t) dt ds$$

gäller sägs (X, Y) vara kontinuerlig.

$f_{X,Y}(x, y)$ kallas *simultana täthetsfunktionen* för (X, Y) .

För *täthetsfunktionen* gäller

$$f_{X,Y}(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y} \quad \text{och} \quad \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx dy = 1$$

Den *marginella sannolikhetsfunktionen* för X fås ur

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$$

Oberoende stokastiska variabler

Definition

X och Y sägs var oberoende stokastiska variabler om

$$p_{X,Y}(j, k) = p_X(j)p_Y(k) \quad \textit{diskreta}$$

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) \quad \textit{kontinuerliga}$$

gäller för alla j och k , x och y .

Jmf definitionen av oberoende händelse

$$P(A \cap B) = P(A)P(B)$$

Väntevärde, lägesmått (centralmått)

- Om X är en stokastisk variabel med utfallsrummet Ω definieras väntevärdet för X , $E[X]$ ofta betecknat μ , av

$$E[X] = \sum_i x_i P(X = x_i), X \text{ diskret}$$

$$E[X] = \int_{-\infty}^{\infty} x f(x) dx, X \text{ kontinuerlig}$$

- Väntevärdet anger tyngdpunkten i en fördelning
- Är ett teoretiskt medelvärde, ett medelvärde man kan förvänta sig om man gör upprepade försök

Sats 1 & 2

Om $Y = g(X)$ gäller

$$E(Y) = E(g(X)) = \sum_x g(x)p(x), \quad X \text{ diskret}$$

$$E(Y) = E(g(X)) = \int_{\Omega} g(x)f(x)dx, \quad \text{om } X \text{ kont.}$$

Om $Z = g(X, Y)$ gäller

$$E(Z) = E(g(X, Y)) = \sum_{x \in \Omega_X} \sum_{y \in \Omega_Y} g(x, y)p_{X,Y}(x, y) \quad \text{om } X, Y \text{ diskret}$$

$$E(Y) = E(g(X, Y)) = \int_{\Omega_X} \int_{\Omega_Y} g(x, y)f_{X,Y}(x, y)dydx \quad \text{om } X, Y \text{ kont.}$$

Sats 3

$$E(g(X) + h(X)) = E(g(X)) + E(h(X))$$

dvs E är en linjär operator

Standardavvikelse och varians, spridningsmått

Definition

- Om X är stokastisk variabel med väntevärdet $E[X] = \mu$, definieras variansen för X , $V(X)$, ofta betecknad σ^2 , som

$$V[X] = E[(X - \mu)^2]$$

$$E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx, X \text{ kont.}$$


$$E[(X - \mu)^2] = \sum_x (x - \mu)^2 p(x), X \text{ diskret}$$

- Standardavvikelsen för X , $\sigma = D(X) = \sqrt{V[X]}$

Andra läges och spridningsmått

Median, kvartil och percentil

- Den stokastiska variabeln X har fördelningsfunktionen $F(x)$. Medianen definieras som det tal, m , som uppfyller
$$F(m) = 0,5$$
- Den stokastiska variabeln X har fördelningsfunktionen $F(x)$. Den p :te percentilen definieras som det tal L_p som uppfyller
$$F(L_p) = p\% = (p/100)$$
- Med kvartiler avses $Q_1 = L_{25}$, $Q_2 = L_{50}$ (medianen) och $Q_3 = L_{75}$.



Några räkneregler för väntevärde och varians

Sats 6

$$V(X) = E[(X - \mu)^2] = E(X^2) - \mu^2$$

$$\text{Där } E(X^2) = \begin{cases} \sum_{k \in \Omega} x^2 p(x), & X \text{ diskret} \\ \int_{-\infty}^{\infty} x^2 f(x) dx, & X \text{ kontinuerlig} \end{cases}$$

Sats 7

$$E[aX+b] = aE[X]+b \qquad V[aX+b] = a^2V[X]$$

$$a, b \in \mathbb{R} \qquad D[aX+b] = |a|D[X]$$

Beroendemått

Definition

Kovariansen för X och Y definieras av

- $C(X, Y) = E((X - \mu_1)(Y - \mu_2)) = E(XY) - E(X)E(Y)$
- Om $C(X, Y) = 0$ sägs X och Y okorrelerade
dvs $E(XY) = E(X)E(Y)$
- *Korrelationskoefficienten* för X och Y ges av

$$\rho(X, Y) = \frac{C(X, Y)}{D(X)D(Y)}$$

det gäller att $-1 \leq \rho \leq 1$

Fler räkneregler för väntevärden

Produkt (sats 4 & 9)

- Om X och Y är oberoende stokastiska variabler gäller

$$C(X, Y) = 0 \Leftrightarrow E(XY) - E(X)E(Y) = 0 \Leftrightarrow E(XY) = E(X)E(Y)$$

Summa och differens (sats 10)

- För alla stokastiska variabler X och Y gäller

$$\begin{aligned} E(X \pm Y) &= E(X) \pm E(Y) \\ V(X \pm Y) &= V(X) + V(Y) \pm C(X, Y) \end{aligned}$$

- Om X och Y är oberoende stokastiska variabler gäller dessutom

$$V(X \pm Y) = V(X) + V(Y)$$

$$D(X \pm Y) = \sqrt{V(X) + V(Y)}$$

Fler räkneregler för väntevärden

Aritmetiskt medelvärde (sats 11.2 & 11.3)

Om X_1, X_2, \dots, X_n är oberoende och likafördelade stokastiska variabler dvs $E[X_i] = \mu$ och $V[X_i] = \sigma^2$, $i=1, \dots, n$

$$\text{Låt } Y = \sum_{i=1}^n X_i$$

Då gäller

$$E[Y] = n\mu \text{ och}$$

$$V[Y] = n\sigma^2$$

$$\text{Sätt } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Då gäller

$$E[\bar{X}] = \mu \text{ och } V[\bar{X}] = \sigma^2/n$$

Sats 12 (Stora talens lag)

Låt X_1, X_2, \dots vara oberoende och likafördelade stokastiska variabler med $E(X_i) = \mu$. Sätt

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i. \text{ Då gäller, för alla } \varepsilon > 0, \text{ att}$$

$$P(\mu - \varepsilon < \bar{X} < \mu + \varepsilon) \rightarrow 1, n \rightarrow \infty$$

Sats 13 (Markovs olikhet)

För $a > 0$ och $Y \geq 0$ gäller

$$P(Y \geq a) \leq \frac{E(Y)}{a}$$

Tjebysjovs olikhet (sats 14)

För varje $k > 0$ gäller


$$P(|X - \mu| \geq k\sigma) \leq 1/k^2$$

Normalfördelningen

Normalfördelningen används ofta till att beskriva variationen hos olika företeelser. Mycket viktig, stora delar av statistikteorin bygger på normalfördelningen.

- Normalfördelningen bestäms av två parametrar lägesparametern, μ , samt spridningsparametern, σ

$$X \in N(\mu, \sigma)$$



$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)} \quad -\infty < x < \infty$$

$$F(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-(t-\mu)^2/(2\sigma^2)} dt \quad -\infty < x < \infty$$

Standardnormalfördelning


Med $\mu = 0$ och $\sigma = 1$ fås det viktiga specialfallet $X \in N(0,1)$

Man kallar X för en *standardnormalfördelad stokastisk variabel*.

Täthetsfunktionen betecknas med $\varphi(x)$ och fördelningsfunktionen med $\Phi(x)$, vilken finns tabellerad i slutet av boken.

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \quad -\infty < x < \infty$$

$$\Phi(x) = \int_{-\infty}^x \phi(t) dt = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$



$\varphi(x)$ är en jämn funktion och är symmetriskt kring 0.

Detta ger egenskapen: $\Phi(-x) = 1 - \Phi(x)$

Allmänna egenskaper

Sats 1

Om $X \in N(\mu, \sigma)$ och $Y = \frac{X - \mu}{\sigma}$

Då blir $Y \in N(0, 1)$

Sats 2

Om $X \in N(\mu, \sigma)$ då är $E(X) = \mu$ och $D(X) = \sigma$.

Dessutom gäller

$Y = aX + b \in N(a\mu + b; |a|\sigma)$

Allmänna egenskaper forts.

För alla normalfördelningar gäller:

$$P(\mu - \sigma < X < \mu + \sigma) = 0.682$$

$$P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.954$$

$$P(\mu - 3\sigma < X < \mu + 3\sigma) = 0.997$$

$$P(\mu - 1.96\sigma < X < \mu + 1.96\sigma) = 0.95$$

$$P(\mu - 2.58\sigma < X < \mu + 2.58\sigma) = 0.99$$

$$P(\mu - 3.29\sigma < X < \mu + 3.29\sigma) = 0.999$$

Fler egenskaper

Sats 4

Om $X_1 \in N(\mu_1; \sigma_1)$, Om $X_2 \in N(\mu_2; \sigma_2)$ och oberoende gäller

$$X_1 + X_2 \in N(\mu_1 + \mu_2; \sqrt{\sigma_1^2 + \sigma_2^2})$$

$$X_1 - X_2 \in N(\mu_1 - \mu_2; \sqrt{\sigma_1^2 + \sigma_2^2})$$

Sats 5 och 6

Om $X_i \in N(\mu_i; \sigma_i)$ och oberoende samt $c_i \in \mathbb{R}$ och är givna,
 $i = 1, \dots, n$ så gäller

$$\sum_{i=1}^n X_i \in N\left(\sum_{i=1}^n c_i \mu_i; \sqrt{\sum_{i=1}^n c_i^2 \sigma_i^2}\right) \quad \text{med } \mu_i = \mu \text{ fås}$$

$$\sum_{i=1}^n X_i \in N(n\mu; \sqrt{n}\sigma) \quad \text{och} \quad \bar{X} \in N(\mu; \sigma/\sqrt{n})$$

Centrala gränsvärdessatsen

Låt X_1, X_2, \dots, X_n vara oberoende och likafördelade stokastiska variabler med väntevärdet μ och standardavvikelsen σ

$$P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \leq x\right) \rightarrow \Phi(x), n \rightarrow \infty$$

Praktiskt: summan av antal slumpvariabler är approximativt normalfördelade om n är stort. (Tumregel $n > 30$)

Normalapproximationer är mycket användbara

Om n är stort så gäller \bar{X} är approximativt $N(\mu, \sigma/\sqrt{n})$

$\sum_{i=1}^n X_i$ är approximativt normalfördelad $N(n\mu, \sigma\sqrt{n})$

Binomialfördelningen

- Ett försök består av n upprepningar av oberoende delförsök, (ex: dragning med återlägg). A är en speciell händelse som inträffar med sannolikheten p i varje delförsök. Slumpvariabeln X betecknar antalet gånger händelsen A inträffar i hela försöket. X blir då binomialfördelad

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, x = 0, 1, 2, \dots, n$$

$$X \in \text{Bin}(n, p)$$

”oberoende upprepningar med samma sannolikhet”

Binomialfördelningen

Egenskaper

Sats 2

Om $X \in \text{Bin}(n, p)$ så är

$$E(X) = np \quad V(X) = np(1-p) \quad D(X) = \sqrt{np(1-p)}$$

Sats 3

Om $X \in \text{Bin}(n_1; p)$ och $Y \in \text{Bin}(n_2; p)$, X och Y oberoende, så blir $X + Y \in \text{Bin}(n_1 + n_2; p)$

Binomialfördelningen

Approximativa egenskaper.

Om $X \in \text{Bin}(n, p)$ och $V(X) > 10$ så är
 $X \approx N(np; \sqrt{np(1-p)})$


Om $X \in \text{Bin}(n, p)$ och $p < 0.1$ så är
 $X \approx \text{Po}(np)$

Hypergeometrisk fördelning

- En mängd innehåller totalt N element, av vilka Np är av speciellt slag (andelen speciella är p). Välj slumpmässigt, utan återläggning, ett urval av n element. Slumpvariabeln X betecknar antalet speciella element i urvalet. X blir då hypergeometriskt fördelad.

$$P(X = x) = \frac{\binom{Np}{x} \binom{N - Np}{n - x}}{\binom{N}{n}}$$

x är ett heltal sådant att $0 \leq x \leq Np$
och $0 \leq n - x \leq N - Np$



$$X \in \text{Hyp}(N, n, p)$$

Hypergeometrisk fördelning

Egenskaper Sats 6

Om $X \in \text{Hyp}(N, n, p)$ så är

$$E(X) = np \quad V(X) = np(1-p) \frac{N-n}{N-1} \quad D(X) = \sqrt{np(1-p) \frac{N-n}{N-1}}$$

Approximativa egenskaper

Om $X \in \text{Hyp}(N, n, p)$

- 1. och $V(X) > 10$ så är $X \approx N(np; \sqrt{np(1-p) \frac{N-n}{N-1}})$*
- 2. och $n/N < 0.1$ så är $X \approx \text{Bin}(n, p)$*
- 3. och $p + n/N < 0.1$ så är $X \approx \text{Po}(np)$*


Poissonfördelning

- Betrakta händelser A som slumpmässig och oberoende av varandra inträffar i tiden. Slumpvariabeln X betecknar antalet händelser A som inträffar under ett tidsintervall av fix längd. X blir då poissonfördelad

$$P(X = x) = e^{-\mu} \frac{\mu^x}{x!}, x = 0, 1, \dots$$

μ – kallas intensitetsparameter

μ anger genomsnittligt antal händelser A under tiden t



$X \in Po(\mu)$

Poissonfördelning

Egenskaper

Sats 7 Om $X \in Po(\mu)$ så är
 $E(X) = \mu$, $V(X) = \mu$ och $D(X) = \sqrt{\mu}$


Sats 8 Om $X \in Po(\mu_1)$ och $Y \in Po(\mu_2)$, X och Y oberoende,
så är $X + Y \in Po(\mu_1 + \mu_2)$

Approximativa egenskaper

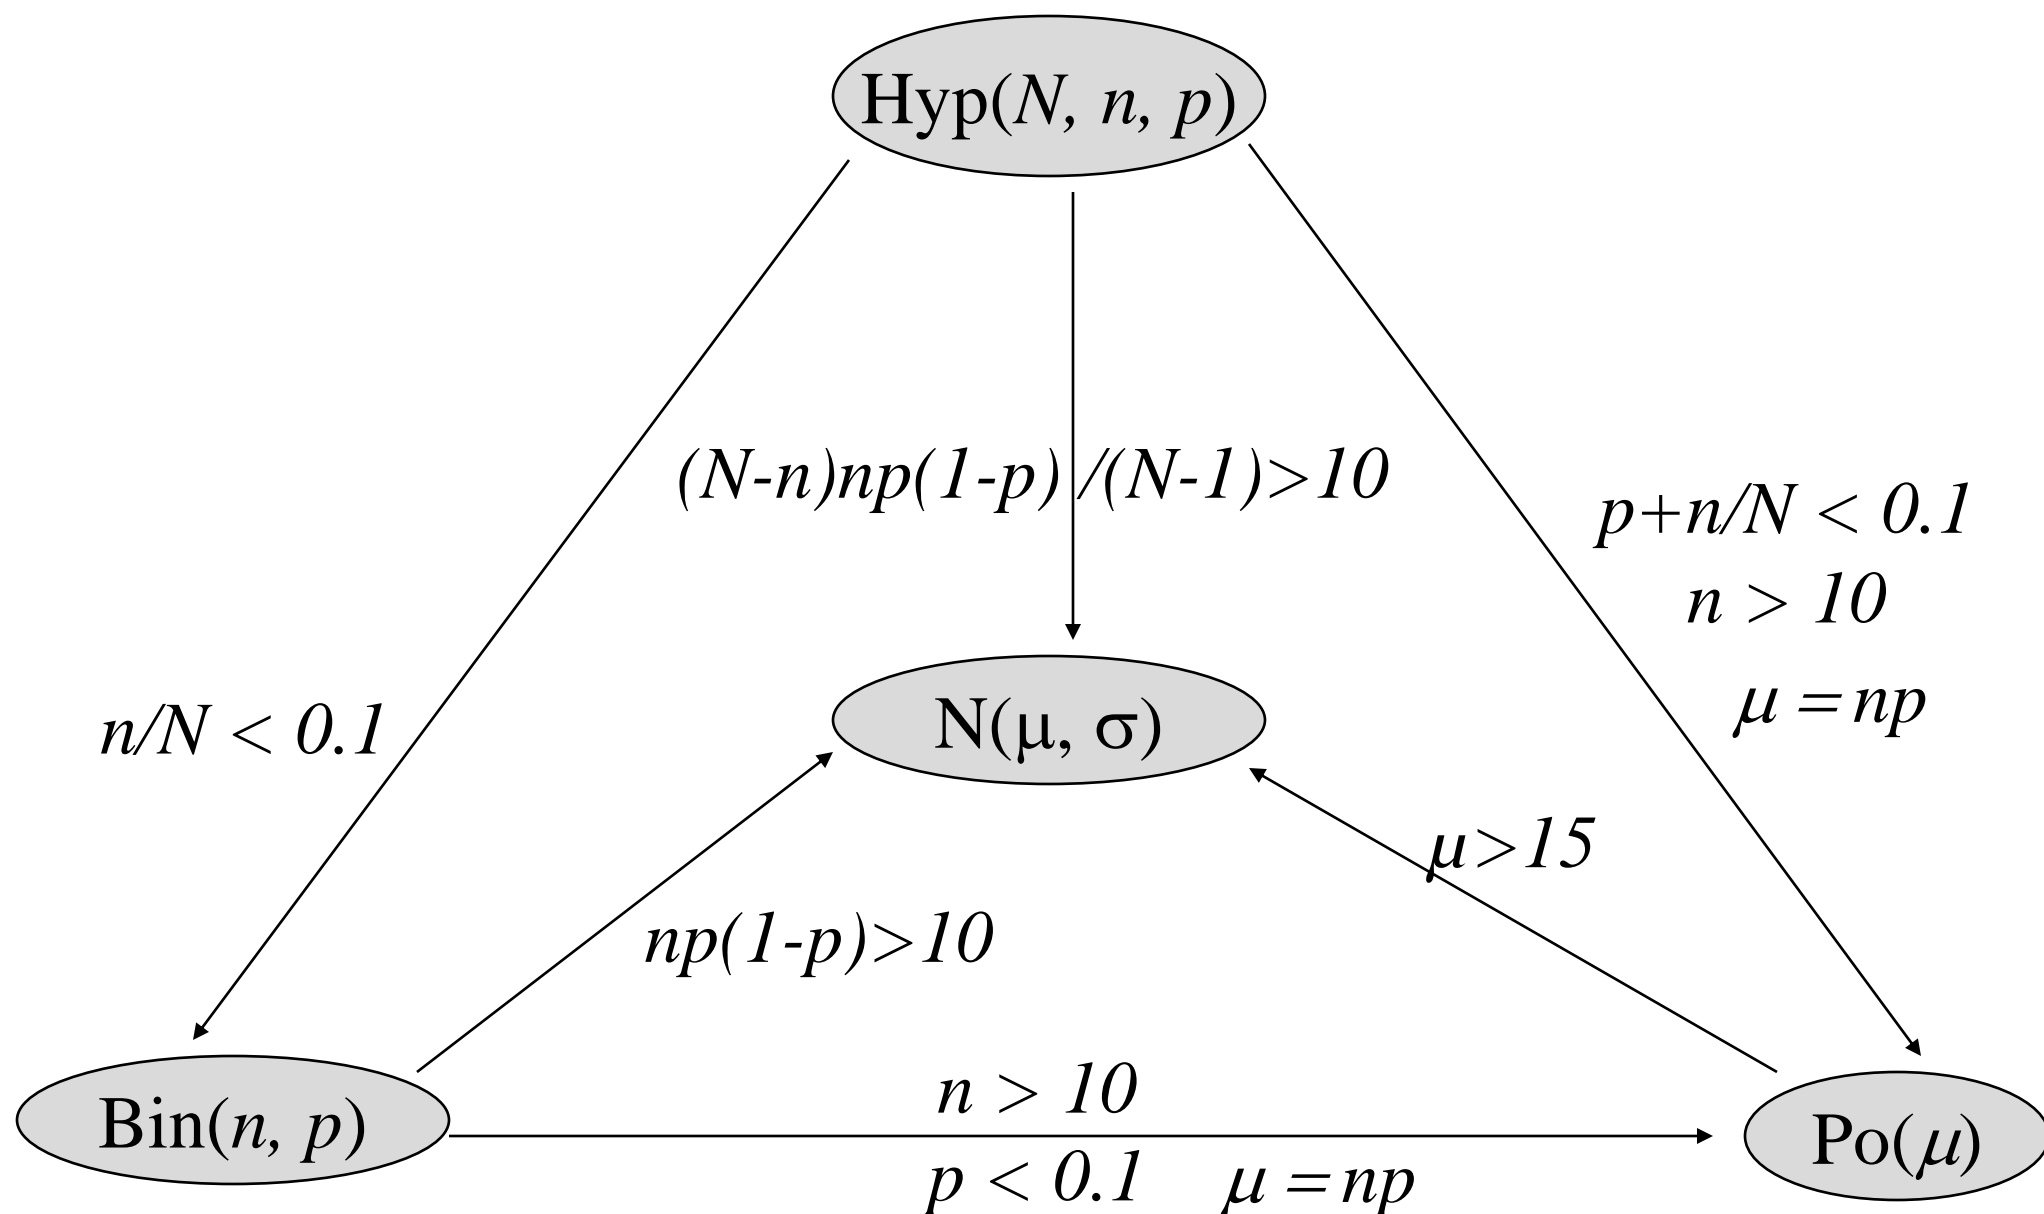
Om $X \in Po(\mu)$ och $\mu > 15$
så är $X \approx N(\mu, \sqrt{\mu})$

Hypergeometrisk, binomial och poisson fördelning

Approximationsregler



Approximationsregler - centrala gränsvärdessatsen



Gauss approximationsformler

- X är en stokastisk variabel med vänta värde $E[X] = \mu$ och varians $V[X] = \sigma^2$ och g är en funktion med kontinuerlig derivata

Då gäller $E[g(X)] \approx g(\mu)$ och $V[g(X)] \approx (g'(\mu))^2 \sigma^2$

- X_1 och X_2 är oberoende stokastiska variabler med vänta värde m_1 och m_2 samt varianser σ_1^2 och σ_2^2
- g är en funktion av två variabler x_1 och x_2

Då gäller $E[g(X_1, X_2)] \approx g(\mu_1, \mu_2)$ och

$$V[g(X_1, X_2)] \approx \left(\frac{\partial g(\mu_1, \mu_2)}{\partial x_1} \right)^2 \sigma_1^2 + \left(\frac{\partial g(\mu_1, \mu_2)}{\partial x_2} \right)^2 \sigma_2^2$$